

Proyecto 1: Analizador Léxico

Jueves 24 de Setiembre

I. DESCRIPCIÓN

En este proyecto, Ud deberá desarrollar un *scanner* para el Lenguaje C. Toda la programación debe realizarse en C sobre Linux, usando la herramienta *flex*. La salida es una presentación Beamer que será desplegada automáticamente desde su programa. No se pueden cambiar las especificaciones de este documento.

II. EJECUCIÓN

El programa se invocará desde la línea de comando de una consola. Recibirá como argumento el nombre del archivo fuente a ser procesado¹, junto con cualquier opción al estilo tradicional de UNIX/Linux. Los argumentos deben venir de la línea de comando. Por favor hacer esto correctamente o el proyecto no será revisado.

III. PREPROCESO

Antes de empezar el análisis léxico, su programa debe manejar una forma básica de preproceso que genera un nuevo archivo temporal con el fuente después del preproceso. Este archivo es la verdadera entrada al *scanner*. No borre este archivo, ni use un nombre alambrado para poder hacer un mejor trabajo de pruebas y evaluación.

Se siguen las mismas reglas sintácticas del preprocesador de C (el cual es muy estricto y limitado - afortunadamente). Nos limitaremos a las siguientes directivas:

- **#include:** permite incluir un archivo de texto como parte del fuente (tampoco hagan ninguna suposición respecto a la extensión o contenido de este archivo). Dicho archivo siempre reside en el directorio actual y nótese que puede contener de nuevo directivas de preproceso que deben ser tomadas en cuenta.
- **#define:** asocia un nombre (con las mismas reglas de los nombres de variables) con una hilera de texto formada por el resto de los caracteres de la línea del archivo. Cualquier aparición del mismo nombre en el resto del fuente debe ser reemplazada por la hilera asociada. Esta hilera podría contener otros símbolos definidos con **#define** que deben ser expandidos. Para este proyecto no se manejarán macros con parámetros.

Trabajo extra opcional 1: Manejar macros con parámetros

Es responsabilidad de su preprocesador eliminar los comentarios contenidos en el archivo de entrada (manejar las dos formas de comentarios de C).

IV. SCANNER

Usando la herramienta *flex*, es relativamente fácil generar la mayor parte (sino todo) del código de un analizador léxico o *scanner*². En este caso, se pide que Ud. escriba un *scanner* para el lenguaje C completo, tal y como está descrito en la documentación oficial del lenguaje.

Su código deberá presentar una función semejante al `Get-Token()` estudiado en clases, la que, al ser invocada, regresará el siguiente *token* del fuente procesado, en alguna estructura de datos apropiada que tenga cosas como: código de *token*, puntero al lexema, valor numérico del lexema, etc. Estructure su programa de tal manera que `Get-Token()` sea independiente del resto del código para posibles usos en proyectos futuros.

La entrada a esta parte de su programa es el archivo de texto temporal generado por el preprocesador, que presumiblemente es un programa escrito en C, pero en realidad podría ser cualquier archivo, ya sea de texto o binario.

V. SALIDA

Su programa debe producir una presentación Beamer con los resultados descritos más abajo. Esto implica, en primer lugar, generar un programa fuente de $\text{\LaTeX}$. Internamente, se ejecutará el comando `pdflatex` para que procese dicho archivo y que genere un PDF, el cual será desplegado de inmediato (posiblemente usando el comando `evince`) en modo presentación.

Se espera una presentación Beamer de gran calidad (con tablas, colores, dibujos, imágenes, gráficos, etc.) que incluirá como mínimo lo siguiente:

- Un *slide* de portada identificando al grupo de trabajo, al semestre del curso, y al proyecto.
- Varios *slides* con una explicación general del proceso de *scanning* y de la herramienta *flex*.
- Múltiples *slides* con el programa fuente que le entró a la fase de *scanning* (i.e., después del preproceso), pero con una clara distinción de cada lexema. Utilice distintos tipos de letra, pesos, inclinaciones y combinaciones de colores (juegos de *foreground* y *background*) para cada categoría léxica. Los errores léxicos deben ser reportados de la misma manera. Ponga una cantidad razonable de líneas del fuente original en cada *slide*.

¹Tiene que aceptar cualquier tipo de extensión

²Considere también el uso de *flex* para su preprocesador.

- Histograma de las cantidades de cada tipo de *token* encontrados en el fuente. Para esto, podrían preparar internamente un archivo de datos e invocar al comando `gnuplot` desde su programa o usar el package `pgfplots` de $\text{\LaTeX}$.
- Gráfico de pastel de las categorías léxicas encontradas (misma información que el histograma). Se debe usar indispensablemente el package `pgfplots` de $\text{\LaTeX}$.

VI. REQUISITOS INDISPENSABLES

La ausencia de uno solo de los siguientes requisitos vuelve al proyecto “no revisable” y recibe un 0 de calificación inmediata:

- La colaboración entre grupos se considera fraude académico.
- Utilizar código, archivos de datos, pruebas o documentación de semestres previos (*e.g.*, buscando en `GitHub`) o usar IA para completar cualquier parte de su trabajo no sólo es fraude académico, es una aceptación de incompetencia e inutilidad.
- Todo el código debe estar escrito en C (no C++).
- Deben usar `flex`.
- El proyecto debe compilar y ejecutar en Linux. Todo debe estar **integrado**, explicaciones del tipo “*todo está bien pero no pudimos pegarlo*”³ provocan la cancelación automática de la revisión.
- La presentación debe ser de mucha calidad.
- Para el momento de la revisión, su programa no debe tener “prints” de depuración. Luce muy poco profesional.
- La única interacción válida con el programa es por medio de argumentos de línea de comando.
- No debe dar “Segmentation Fault” bajo ninguna circunstancia.
- La demostración debe hacerse en una máquina que levante Linux de manera real (puede ser dual), es decir no usar máquinas virtuales. No se puede levantar de un disco o memoria externa. No se pueden prestar máquinas entre grupos.

VII. FECHA DE ENTREGA

Demostraciones el **Jueves 24 de Setiembre** en la clase. Mande además un `.tgz` con todo lo necesario (fuentes, `makefile`, `readme`, etc.) a `torresrojas.cursos.02@gmail.com`.

Pongan como subject:

[COM] Proyecto 1 – Fulano – Mengano –
etc

, donde Fulano, Mengano, etc. son los miembros del grupo.
Mucha suerte...

³esto incluye los supuestos casos cuando alguien del grupo de trabajo no hizo su parte – el profesor no está interesado en sus problemas de organización.